

Министерство науки и высшего образования Российской Федерации Федеральное государственное бюджетное образовательное учреждение высшего образования

«Московский государственный технический университет имени Н.Э. Баумана

(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _	«Информатика и системы управления»
КАФЕДРА	«Программное обеспечение ЭВМ и информационные технологии»

Отчёт

по лабораторной работе №1

Название: _	Расстояния Левенштейна и Дамерау-Левенштейна					
Дисциплина:	Анализ алгоритмо	В				
Студент	ИУ7-52Б		Д.В. Батраков			
	(Группа)	(Подпись, дата)	(И.О. Фамилия)			
Преподователь			Л.Л. Волкова			
		(Подпись, дата)	(И.О. Фамилия)			

Содержание

Вв	едение		3
1	Анали	итический раздел	4
	1.1	Цель и задачи практики	4
	1.2	Расстояние Левенштейна	4
	1.3	Расстояние Дамерау-Левенштейна	5
2	Конст	укторский раздел	6
	2.1	Разработка алгоритмов	6
	2.2	Требования к функциональности ПО	6
	2.3	Тесты	6
3	Техно	логический раздел	11
	3.1	Средства реализации	11
	3.2	Листинг программы	13
	3.3	Тестирование	17
	3.4	Сравнительный анализ потребляемой памяти	18
4	Экспер	риментальный раздел	19
	4.1	Сравнительный анализ на основе замеров времени работы алгоритмов	19
	4.2	Вывод	19
201	ZHIOHOH		22

Введение

В данной работе требуется изучить и применить алгоритмы нахождения расстояния Левенштейна и Дамерау-Левенштейна, а также получить практические навыки реализации указанных алгоритмов.

Расстояния Левенштейна и Дамерау-Левенштейна применяется для следующих задач:

- 1) для автозамены, в том числе в поисковых системах;
- 2) в биоинформатике для сравнения цепочек белков, генов и т.д.

1 Аналитический раздел

1.1 Цель и задачи практики

Цель: реализовать и сравнить по эффективности алгоритмы поиска расстояния Левенштейна и Дамерау-Левенштейна.

Задачи:

- 1) дать математическое описание расстояний Левенштейна и Дамерау-Левенштейна;
- 2) разработать алгоритмы поиска расстояний Левенштейна и Дамерау-Левенштейна;
- 3) реализовать алгоритмы поиска расстояний Левенштейна и Дамерау-Левенштейна;
- 4) провести эксперименты по замеру времени работы реализованных алгоритмов;
- 5) проанализировать реализованные алгоритмы по затраченному времени и максимально затраченной памяти.

1.2 Расстояние Левенштейна

Расстояние Левенштейна (или редакционное расстояние) – это минимальное количество редакционных операций, которое необходимо для преобразования одной строки в другую.

Редакционными операциями являются:

- 1) вставка (I Insert);
- 2) удаление (D Delete);
- 3) замена (R Replace);
- 4) совпадение (M Match).

Операции I, D, R имеют штраф 1, а операция M-0.

Пусть s_1 и s_2 — две строки (длиной M и N соответственно) в некотором алфавите V, тогда расстояние Левенштейна можно подсчитать по рекуррентной формуле (1.1):

$$D(s1[1..i], s2[1..j]) = \begin{cases} 0, & i = 0, j = 0 \\ i, & j = 0, i > 0 \\ j, & i = 0, j > 0 \\ min(s1[1..i], s2[1..j - 1]) + 1, & j > 0, i > 0 \\ D(s1[1..i - 1], s2[1..j]) + 1, & j > 0, i > 0 \\ D(s1[1..i - 1], s2[1..j - 1]) + M(s1[i], s2[j]), \end{cases}$$

$$(1.1)$$

где
$$s[1..k]$$
 - подстрока длиной k и $M(a,b)=\left\{ egin{array}{ll} 0, & a=b \\ 1, & a
eq b \end{array} \right.$

В Таблице 1.1 минимальное расстояние между словом "кот"и "скат"равно 2. Последовательность редакторских операций, которая привела к ответу - IMRM.

Таблица 1.1 — Пример работы преобразования слова "кот"в "скат"

	λ	С	K	A	Т
λ	0	1	2	3	4
K	1	1	1	2	3
О	2	2	2	2	3
Т	3	3	3	3	2

1.3 Расстояние Дамерау-Левенштейна

Расстояние Дамерау-Левенштейна является модификацией расстояния Левенштейна: к операциям вставки, удаления и замены символов, добавлена операция транспозиции (перестановки двух соседних символов) (X - exchange). Операция транспозиции возможна, если символы попарно совпадают.

Пусть s_1 и s_2 — две строки (длиной M и N соответственно) в некотором алфавите V, тогда расстояние Дамерау-Левенштейна можно подсчитать по рекуррентной формуле (1.2):

$$D(s1[1..i], s2[1..j]) = \begin{cases} max(i, j), & min(i, j) = 0 \\ s1[1..i], s2[1..j - 1] + 1 \\ s1[1..i - 1], s2[1..j] + 1 \\ s1[1..i - 2], s2[1..j - 2] + 1 \\ s1[1..i - 1], s2[1..j - 1] + M(s[i], s[j]) \end{cases}$$

$$(1.2)$$

2 Констукторский раздел

В данном разделе будут рассмотрены схемы алгоритмов, требования к функциональности ПО, и опредены способы тестирования.

2.1 Разработка алгоритмов

Ниже будут представлены схемы алгоритмов поиска растояния Левенштейна:

- 1) нерекурсивного с заполнением матрицы (рисунок 2.1);
- 2) рекурсивного без заполнения матрицы (рисунок 2.2);
- 3) рекурсивного с заполнением матрицы (рисунок 2.3).

Также будет представлена схема нерекурсивного алгоритма поиска растояния Дамерау-Левенштейна (рисунок 2.4).

2.2 Требования к функциональности ПО

В данной работе требуется обеспечить следующую минимальную функциональность консольного приложения.

- 1) Режим ввода:
 - а) возможность считать две строки;
 - б) вывод расстояний Левенштейна и Дамерау-Левенштейна между строками;
 - в) вывод матриц, используемых в вычислении расстояний (если использовались).
- 2) Экспериментальный режим:
 - а) вывод таблицы с процессорным временем [?] работы.

По умолчанию приложение работает в режиме ввода, для перехода в режим тестирования необходимо указать ключ -t при запуске.

2.3 Тесты

Тестирование ПО будет проводиться методом чёрного ящика. Необходимо проверить работу системы на тривиальных случаях (одна или обе строки пустые, строки полностью совпадают) и несколько нетривальных случаев.

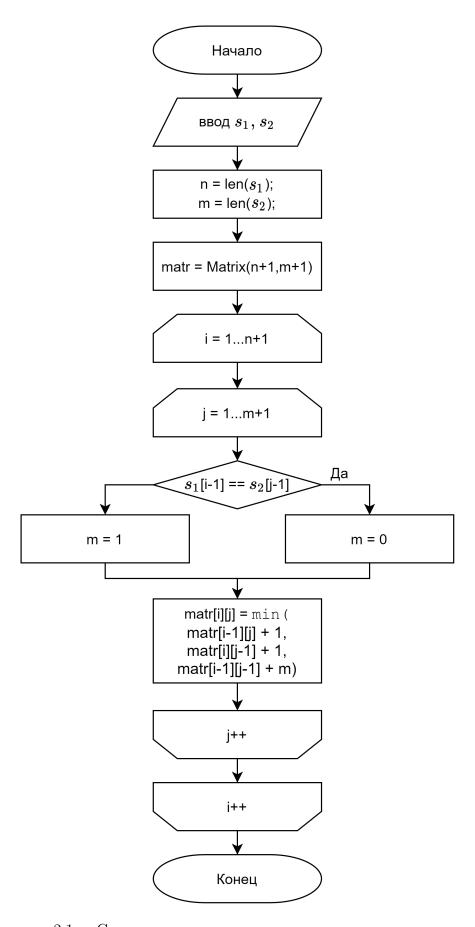


Рисунок 2.1 — Схема нерекурсивного поиска с заполнением матрицы

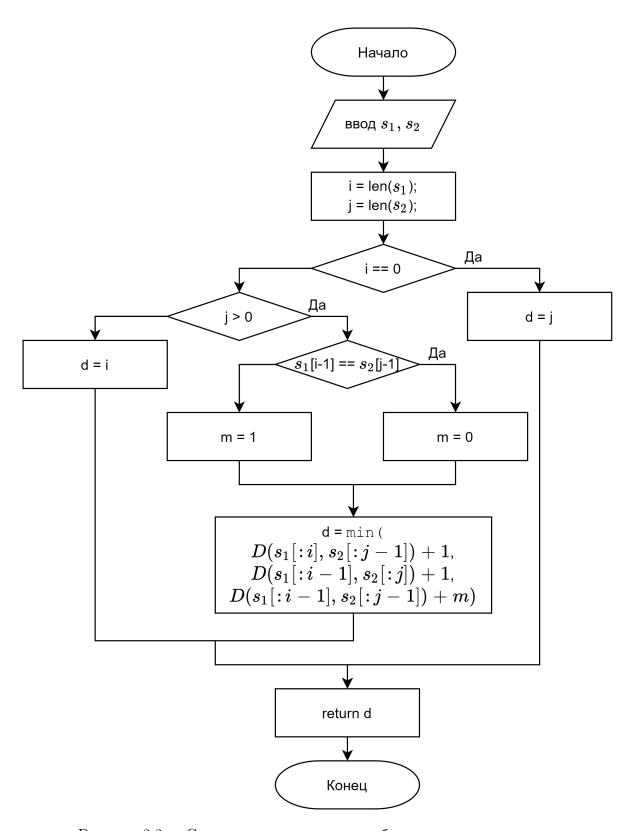


Рисунок 2.2 — Схема рекурсивого поиска без заполнения матрицы

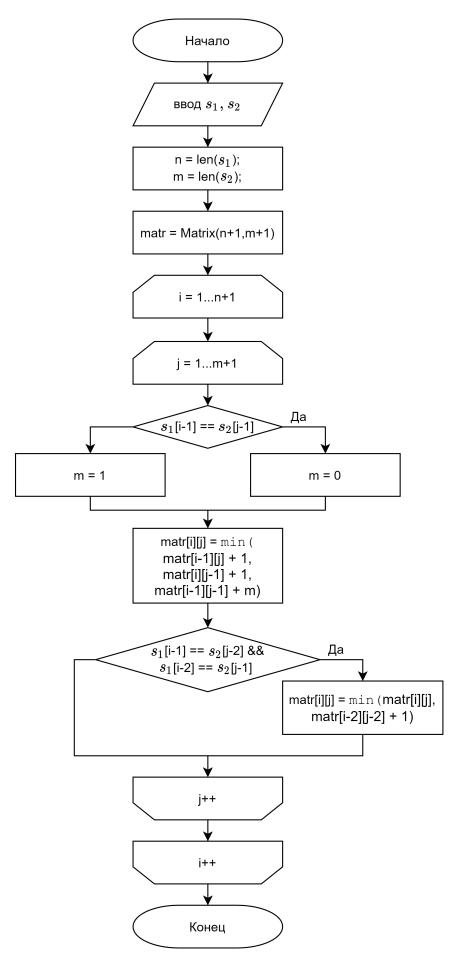


Рисунок 2.3 — Схема рекурсивого поиска с заполнением матрицы




Рисунок 2.4 — Схема поиска р. Дамерау-Левенштейна

3 Технологический раздел

В данном разделе будут выбраны средства реплизации ПО, представлен листинг кода и проведён теоритический анализ максимальной затрачиваемой памяти.

3.1 Средства реализации

В данной работе используется язык программирования C++, так как язык позволяет написать программу, работающую относительно быстро. Проект выполнен в IDE CLion [?].

Для замера процессорного времени была использована функция getCPUTime [?] реализованная David Robert Nadeau для Linux и Windows , использование которой представлено в листинге 3.1.

Листинг $3.1 - \Phi$ ункция замера времени

```
1
 2
   * Author: David Robert Nadeau
 3
 4
   * Site:
              http://NadeauSoftware.com/
   * License: Creative Commons Attribution 3.0 Unported License
 5
 6
               http://creativecommons.org/licenses/by/3.0/deed.en US
 7
   #if defined (WIN32)
8
   #include <Windows.h>
9
10
   #elif defined(__unix__) || defined(__unix) || defined(unix) || (defined(__APPLE__)
11
      && defined ( MACH ))
   #include <unistd.h>
12
   #include <sys/resource.h>
13
   #include <sys/times.h>
14
   #include <time.h>
15
16
   #else
17
   #error "Unable to define getCPUTime( ) for an unknown OS."
   #endif
19
20
   /**
21
   * Returns the amount of CPU time used by the current process,
22
   * in seconds, or -1.0 if an error occurred.
23
24
   */
   double getCPUTime( )
25
26
   #if defined (WIN32)
27
   /* Windows —
28
   FILETIME createTime;
29
30
   FILETIME exitTime;
```

```
FILETIME kernelTime;
31
32
   FILETIME userTime;
   if ( GetProcessTimes( GetCurrentProcess( ),
33
   &createTime, &exitTime, &kernelTime, &userTime) != -1)
34
35
36
   SYSTEMTIME userSystemTime;
   if (FileTimeToSystemTime(&userTime, &userSystemTime)!= −1)
37
   return (double) userSystemTime. wHour * 3600.0 +
38
   (double) userSystemTime.wMinute * 60.0 +
39
   (double) userSystemTime.wSecond +
40
   (double) userSystemTime. wMilliseconds / 1000.0;
41
42
43
   #elif defined(__unix__) || defined(__unix) || defined(unix) || (defined(__APPLE__)
44
      && defined ( MACH ))
   45
46
   #if defined (POSIX TIMERS) && (POSIX TIMERS > 0)
47
   /* Prefer high-res POSIX timers, when available. */
48
49
   clockid_t id;
50
   struct timespec ts;
51
   \#if POSIX CPUTIME > 0
52
53
   /* Clock ids vary by OS. Query the id, if possible. */
   if ( \operatorname{clock\_getcpuclockid} ( 0, \& id ) == -1 )
54
   #endif
55
   #if defined (CLOCK PROCESS CPUTIME ID)
56
   /* Use known clock id for AIX, Linux, or Solaris. */
57
   id = CLOCK PROCESS CPUTIME ID;
58
59
   #elif defined (CLOCK VIRTUAL)
   /* Use known clock id for BSD or HP-UX. */
60
   id = CLOCK VIRTUAL;
61
   #else
62
   id = (clockid t) -1;
63
   #endif
64
   if (id != (clockid t)-1 \&\& clock gettime(id, \&ts) != -1)
65
66
   return (double) ts.tv sec +
67
   (double) ts.tv nsec / 1000000000.0;
68
69
   #endif
70
   #if defined (RUSAGE SELF)
71
72
73
   struct rusage rusage;
74
   if (getrusage(RUSAGE SELF, &rusage)!= −1)
   return (double) rusage.ru utime.tv sec +
75
   (double) rusage.ru_utime.tv_usec / 1000000.0;
```

```
77
78
    #endif
79
    #if defined (_SC_CLK_TCK)
80
81
    const double ticks = (double)sysconf( SC CLK TCK );
82
    struct tms tms;
83
    if (times(\&tms) != (clock t)-1)
84
    return (double)tms.tms utime / ticks;
85
86
    #endif
87
88
    #if defined (CLOCKS PER SEC)
89
90
91
    clock \ t \ cl = clock();
    if (cl != (clock t)-1)
92
    return (double)cl / (double)CLOCKS PER SEC;
93
94
95
    #endif
96
97
    #endif
98
    return −1; /* Failed. */
99
100
```

3.2 Листинг программы

Ниже представлены листинги кода поиска растояния Левенштейна:

- 1) нерекурсивного с заполнением матрицы (листинг 3.2);
- 2) рекурсивного без заполнения матрицы (листинг 3.3);
- 3) рекурсивного с заполнением матрицы (листинг 3.4);

и код функции поиска растояния Дамерау-Левенштейна (листинг 3.5).

Листинг 3.2 — Функция нерекурсивного поиска с заполнением матрицы

```
size_t Levenshtein::withoutRecursion(const std::string& str1, const std::string&
1
     str2, bool debugMode) {
2
     auto len1 = str1.length();
     auto len2 = str2.length();
3
      auto matrix = Matrix(len1 + 1, len2 + 1);
4
5
      for (size_t i = 0; i \le len1; i++)
6
7
         matrix[i][0] = i;
8
```

```
matrix[0][j] = j;
9
10
        for (auto i = 1; i <= len1; i++)
11
12
        {
             for (auto j = 1; j <= len2; j++)
13
14
             {
                 auto m = 1;
15
                 if (str1[i-1] = str2[j-1])
16
                     m = 0;
17
18
                 matrix[i][j] = std :: min(matrix[i - 1][j] + 1,
19
20
                 std::min(matrix[i][j - 1] + 1,
                 matrix\,[\,i\ -\ 1\,]\,[\,j\ -\ 1\,]\ +\, m)\,)\,;
21
            }
22
23
        }
        if (debugMode) {
24
25
             std::cout << "Levenshtein without recursion" << std::endl;</pre>
             matrix.print();
26
27
        }
        return matrix [len1][len2];
28
29
```

Листинг $3.3-\Phi$ ункция рекурсивного поиска без заполнения матрицы

```
1
   size_t Levenshtein::_recursionWithoutCash(const char* str1, size_t i, const char*
      str2, size t j) {
2
      size_t res;
       if (i)
3
4
       {
          if (j)
5
6
          {
7
              auto m = 1;
              if (str1[i - 1] = str2[j - 1])
8
9
              m = 0;
10
              auto a = recursionWithoutCash(str1, i, str2, j - 1) + 1;
11
12
              13
              auto c = recursionWithoutCash(str1, i - 1, str2, j - 1) + m;
              res = std :: min(a, std :: min(b, c));
14
          }
15
16
          else
17
              res = i;
       }
18
       else
19
20
           res = j;
21
       return res;
```

```
22  }
23  
24  size_t Levenshtein::recursionWithoutCash(const std::string &str1, const std::string &str2) {
25    auto i = str1.length();
26    auto j = str2.length();
27    return _recursionWithoutCash(str1.data(), i, str2.data(), j);
28  }
```

Листинг $3.4 - \Phi$ ункция рекурсивного поиска с заполнением матрицы

```
1
 2
   size_t Levenshtein::recursionWithCash(const std::string &str1, const std::string
      &str2, bool debugMode) {
       auto n = str1.length();
 3
       auto m = str2.length();
 4
 5
 6
       auto matrix = Matrix(n + 1, m + 1);
 7
       for (size t i = 0; i \ll n; i++)
 8
9
            for (size t j = 0; j \ll m; j++)
                matrix[i][j] = -1;
10
       }
11
12
13
       auto res = _recursionWithCash(str1.data(), n, str2.data(), m, matrix);
14
       if (debugMode) {
15
            std::cout << "Levenshtein recursion with cash" << std::endl;
            matrix.print();
16
17
       }
18
       return res;
19
20
   size t Levenshtein:: recursionWithCash(const char* str1, size t i, const char* str2,
21
       size_t j, Matrix& matrix) {
22
23
       if (!i)
            matrix[i][j] = j;
24
       else if (!j)
25
            matrix[i][j] = i;
26
       else
27
       {
28
29
            if (matrix[i][j-1] = -1)
                matrix[i][j-1] = _recursionWithCash(str1, i, str2, j-1, matrix);
30
31
            if (matrix[i-1][j] = -1)
                matrix[i - 1][j] = \_recursionWithCash(str1, i - 1, str2, j, matrix);
32
33
            if (matrix[i - 1][j - 1] = -1)
```

Листинг 3.5 — Функция поиска растояния Дамерау-Левенштейна

```
1
 2
   size_t Levenshtein::recursionDamerauWithoutCash(const std::string &str1, const
       std::string &str2) {
        auto i = str1.length();
 3
        auto j = str2.length();
 4
 5
        return _recursionDamerauWithoutCash(str1.data(), i, str2.data(), j);
 6
 7
 8
9
   size t Levenshtein:: recursionDamerauWithoutCash(const char* str1, size t i, const
       char* str2, size t j) {
        size t res;
10
        if (i)
11
12
        {
            if (j)
13
14
            {
                auto m = 1;
15
                if (str1[i - 1] = str2[j - 1])
16
                    m = 0;
17
18
                auto a = \text{recursionWithoutCash}(\text{str1}, i, \text{str2}, j - 1) + 1;
19
20
                auto b = recursionWithoutCash(str1, i - 1, str2, j) + 1;
21
                auto c = recursionWithoutCash(str1, i - 1, str2, j - 1) + m;
22
                 res = std :: min(a, std :: min(b, c));
                 if (i > 1 \&\& j > 1 \&\& str1[i - 1] = str2[j - 2] \&\& str1[i - 2] =
23
                    str2[j-1]
                     res = std :: min(res, recursionWithoutCash(str1, i - 2, str2, j - 2))
24
                        + 1);
            }
25
            else
26
27
                res = i;
28
        }
        else
29
30
            res = j;
31
        return res;
```

3.3 Тестирование

В таблице 3.1 отображён возможный набор тестов для тестирования методом чёрного ящика, результаты которого, представленные на рисунке 3.1, подтверждают прохождение программы перечисленных тестов.

№ строка 1	строка 2	Ожидаемый результат	Фактический результат	
		(р.Л, р.Д-Л)	(р.Л, р.Д-Л)	
1	0	0	0, 0	0, 0
2	0	ab	2, 2	2, 2
3	abba	baab	3, 2	3, 2
4	abcd	qwer	4, 4	4, 4

Таблица 3.1 — Тесты проверки корректности программы

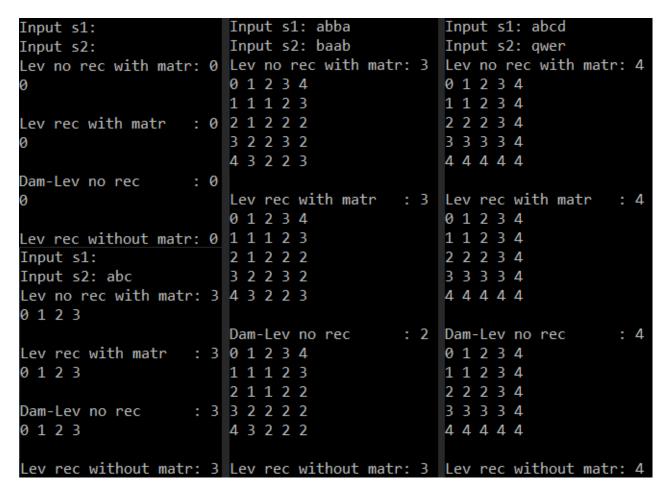


Рисунок 3.1 — Результаты тестирования

3.4 Сравнительный анализ потребляемой памяти

С точки зрения использования памяти алгоритмы Левенштейна и Дамерау-Левенштейна на не отличаются, следовательно, достаточно рассмотреть лишь разницу рекурсивной и матричной реализаций данных методов.

Использование памяти на строках s_1 , s_2 длиной n и m соответственно при использовании матрицы теоритически определяется формулой (3.1):

$$V = (n+1)(m+1)sizeof(int) + 4sizeof(size_t) + 2sizeof(char*) + sizeof(char)(n+m) \quad (3.1)$$

Максимальный расход памяти памяти на строках s_1 , s_2 длиной n и m соответственно при использовании рекурсии определяется максимальной глибиной стека вызовов, которая теоритически определяется формулой (3.2):

$$V = sizeof(char)(n+m) + (n+m)(2sizeof(char) + 3sizeof(size t))$$
(3.2)

4 Экспериментальный раздел

В данном разделе будут проведены эксперименты для проведения сравнительного анализа алгоритмов по затрачиваемому процессорному времени[?] и максимальной используемой памяти.

4.1 Сравнительный анализ на основе замеров времени работы алгоритмов

В рамках данного проекта были проведёны следующие эксперименты:

- 1) сравнение алгоритмов поиска расстояния Левенштейна и Дамерау-Левенштейна на строках длиной от 0 до 4 с шагом 1 (рисунок 4.1);
- 2) сравнение алгоритмов 1 поиска расстояния Левенштейна и Дамерау-Левенштейна на строках длиной от 0 до 1000 с шагом 50 (рисунок 4.2).

Тестирование проводилось на ноутбуке с процессором Intel(R) Core(TM) i5-7200U CPU 2.50 GHz [?] под управлением Windows 10 с 8 Γ б оперативной памяти.

Ниже предствалены графики зависимости времени работы алгоритмов от длины входных строк (рисунки 4.3 и 4.4).

4.2 Вывод

В данном разделе были поставлены эксперименты по замеру времени выполнения каждого из алгоритмов. По итогам замеров не рекурсивный алгоритм нахождения расстояния Левенштейна оказался самым быстродействующим на длинах строк превышающих 3 на 136 % быстрее, чем алгоритм поиска расстояния Левенштейна рекурсивно с заполнением матрицы и на 42 %, чем реализация алгоритм поиска расстояния Дамерау-Левенштейна. На строках длиной менее 3х символов рекурсивная реализиция выигрывает матричные, так как не выделяет в куче место под хранение матрицы.

По расходу памяти матричные алгоритмы проигрывают рекурсивному, так как максимальный размер используемой памяти имеет квадратичную ассимптотику (произведение длин строк), в то время как у рекурсивного - линейная (сумма длин строк).

¹Замеры времени для рекурсивного алгоритма поиска расстояния Левенштейна на строках длиной от 0 до 1000 с шагом 50 не проводились, так как уже на строках длиной 10 алгоритм работает 70 034 ms, что в 35 000 раз больше, времени работы алгоритмов с использованием матрицы. Это связано с экспоненциальной асимптотикой времени выполнения данного алгоритма (пропорционально количеству рекурсивных вызовов).

N - no W - with R - recursion C - cash					
str_len	levNR	levRNC	levRWC	levDamR	1
10	1.2962e-05	4.14e-07	7.67e-07	4.02e-07	1
1	1.002e-06	4.89e-07	8.32e-07	4.67e-07	1
12	8.86e-07	6.28e-07	8.37e-07	6.18e-07	1
3	1.174e-06	1.324e-06	1.17e-06	1.178e-06	1
4	1.403e-06	3.213e-06	1.401e-06	2.972e-06	1
5	1.713e-06	2.991e-05	1.705e-06	2.1366e-05	1

Рисунок 4.1 — Результаты замера времени на строках длиной от 0 до 5

N - no W - with R - recursion C - cash					
str_len	levNR	levRNC	levRWC	levDamR	1
10	2.661e-06	4e-07	7.18e-07	4.96e-07	ı
75	0.000167288	l-1	0.000228132	l-1	ı
150	0.000627072	l-1	0.000944667	l-1	1
225	0.00134542	l-1	0.00213462	l-1	1
300	0.00246606	-1	0.00494261	-1	1
375	0.00495264	l-1	0.00684413	l-1	1
450	0.00539339	l-1	0.00866721	l-1	1
525	0.00732033	-1	0.0119194	-1	1
1600	0.00903693	l-1	0.016115	l-1	ı
675	0.0119257	l-1	0.0209858	l-1	1
750	0.0148076	-1	0.0269556	-1	1
825	0.0175376	-1	0.0331788	-1	1
900	0.0215238	-1	0.0392752	-1	1
975	0.0240596	l-1	0.0441632	l-1	

Рисунок 4.2 — Результаты замера времени на строках длиной от 0 до 975




Рисунок $4.3 - \Gamma$ рафик зависимости времени работы алгоритмов от длин строк




Рисунок 4.4 — График зависимости времени работы алгоритмов от длин строк

Заключение

В ходе работы были изучены и реализованы алгоритмы нахождения расстояния Левенштейна (не рекурсивный с заполнением матрицы, рекурсивный без заполнения матрицы, рекурсивный с заполнением матрицы) и Дамерау-Левенштейна (не рекурсивный с заполнением матрицы). Выполнено сравнение перечисленных алгоритмов.

В ходе экспериментов по замеру времени работы было установлено, что не рекурсивный алгоритм нахождения расстояния Левенштейна на длинах строк превышающих 3 на 136 % быстрее, чем алгоритм поиска расстояния Левенштейна рекурсивно с заполнением матрицы и на 42 %, чем реализация алгоритм поиска расстояния Дамерау-Левенштейна. На строках длиной менее 3х символов рекурсивная реализиция выигрывает матричные, так как не выделяет в куче место под хранение матрицы.

Из теоритического анализа максимальной затрачиваемой памяти каждым из алгоритмов представленым в технологической части можно сделать вывод, что реализации с использованием матриц занимают намного больше памяти при обработке длинных строк, чем рекурсивная реализация, так при длине строк 1000 символов, рекурсивный алгоритм теоритически использует в 95.5 раз меньше памяти, чем остальные.